

Apache Spark, Hadoop HDFS, Apache Hive ve Apache Superset ile Büyük Veri Analitik Pipeline'ı

Faz 2 Veri Ambarı Tasarımı ve İş Analitiği

Ahmet Berat Yıldırım

1. Giriş

Faz 1'de, Olist e-ticaret veri setini 9 ham CSV dosyasından alıp Apache Spark ile Parquet formatına çeviren, Hadoop HDFS'te depolayan, Apache Hive external table'ları üzerinden SQL ile sorgulanabilir hale getiren ve Apache Superset'te genel bir dashboard'a dönüştüren uçtan uca bir pipeline kurulmuştu. O dashboard betimleyici sorulara (zaman içinde sipariş hacmi, popüler kategoriler, coğrafi dağılım) cevap veriyordu, ama her grafik ham tablolara karşı kendi JOIN ve agregasyon mantığını sıfırdan kuruyordu.

Faz 2, Faz 1'in üzerine şu yenilikleri ekliyor:

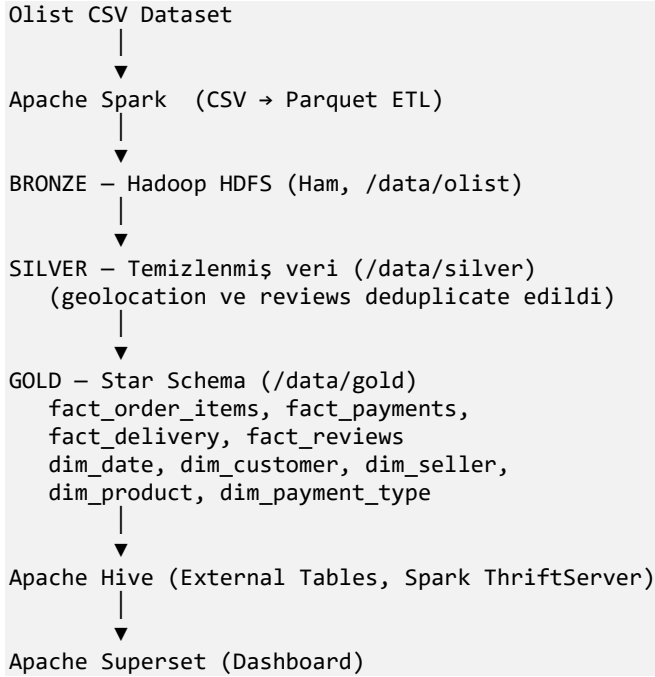
- Veri kalite ölçümü: 9 ham tablonun tamamında null ve duplicate kontrolü gerçekten çalıştırıldı, tahmine dayanmadı.
- Temizlik (Silver katmanı): Ölçümde tespit edilen sorunlu iki tablo (geolocation ve reviews) gerçekten deduplicate edildi.
- Katmanlı mimari: Tek katmanlı ham veri yapısı, Bronze / Silver / Gold olmak üzere 3 katmanlı bir mimariye dönüştürüldü.
- Star schema (Gold katmanı): 7 iş sorusunu cevaplayan 4 fact tablo ve 5 dimension tablodan oluşan boyutsal bir model tasarlanıp Spark ile inşa edildi.
- ETL'den ELT'ye geçiş: Ham veri zaten Hive'da yüklüyken, star schema SQL/Spark dönüşümleriyle üzerine inşa edildi.
- Yeni otomasyon script'leri: data_quality_check.py, build_star_schema.py, register_gold_tables.py.
- Yeni dashboard: 7 iş sorusuna doğrudan cevap veren, star schema üzerine kurulu 7 yeni grafik.

2. Kullanılan Teknolojiler

- Apache Spark: ETL/ELT işleme motoru, star schema inşası
- Hadoop HDFS: Bronze/Silver/Gold katmanlarının dağıtık depolama alanı
- Apache Hive (Spark ThriftServer üzerinden): SQL sorgu katmanı, external table'lar
- Apache Superset: dashboard ve görselleştirme
- Docker / Docker Compose: tüm servislerin container'lar halinde çalıştırılması
- Python (PySpark): veri kalite kontrolü, star schema build script'leri, otomasyon
- SQL: SQL Lab'da JOIN ve agregasyon sorguları
- Apache Parquet: sütunsal, sıkıştırılmış depolama formatı

3. Mimari


Proje, her katmanın tek bir görevi olduğu ve sorgu zamanında yalnızca bir önceki katmanı okuduğu üç katmanlı (Bronze / Silver / Gold) bir mimari izliyor:



Bronze katmanı Faz 1'in tamamı; Silver katmanı ham veriden sadece deduplicate/filtre işlemi yapılmış hali; Gold katmanı ise business question'lara doğrudan cevap veren star schema. Superset yalnızca Gold katmanını sorguluyor, bu sayede her yeni grafik ham tablolara karşı JOIN yazmak yerine tek bir fact tabloya karşı basit bir GROUP BY ile oluşturuluyor.

4. Veri Modeli (ER Diyagramı)

Gold katmanındaki star schema'nın tam yapısı 4 fact tablo, 5 dimension tablo ve aralarındaki foreign key ilişkileri Şekil 1'de gösterilmiştir.



Şekil 1: Star schema ER diyagramı — fact ve dimension tabloları, foreign key ilişkileri.

5. Yapılan Çalışmalar ve Çalıştırılan Kodlar

Faz 2 kapsamında sırasıyla şu adımlar uygulandı:

1. Veri kalite kontrolü çalıştırıldı 9 Bronze tablosunda null ve duplicate ölçümü yapıldı.

```
docker exec -it spark-master /spark/bin/spark-submit \
--master spark://spark-master:7077 \
/app/processing/data_quality_check.py
```

Bulgular: olist_geolocation_dataset'te 261.831 tam satır duplicate; olist_order_reviews_dataset'te 7 null kolon ve 1.204 duplicate review_id; olist_orders_dataset'te 3 tarih kolonunda null; olist_products_dataset'te 8 null kolon. Diğer 5 tablo tamamen temiz çıktı.

2. Silver ve Gold katmanları inşa edildi build_star_schema.py, tespit edilen sorunları temizleyip (Silver) star schema'yı (Gold) oluşturdu.

```
docker exec -it spark-master /spark/bin/spark-submit \
--master spark://spark-master:7077 \
/app/processing/build_star_schema.py
```

Script önce bir şema doğrulaması yaptı: 9 tarih kolonundan 7'si inferSchema ile otomatik timestamp olarak okunmuş, ancak review_creation_date ve review_answer_timestamp string kalmıştı bu ikisi açıkça to_timestamp() ile dönüştürüldü. Ardından geolocation ve reviews tabloları deduplicate edilip Silver'a, 9 dim/fact tablosu da Gold'a Parquet olarak yazıldı.

3. Gold tabloları Hive ve Superset'e kaydedildi register_gold_tables.py, Superset container'ının içine kopyalanıp çalıştırıldı.

```
docker cp visualization/register_gold_tables.py superset:/tmp/register_gold_tables.py
docker exec -it superset python /tmp/register_gold_tables.py
```


4. SQL Lab'da 7 iş sorusu için sorgu yazılıp dataset olarak kaydedildi her sorgu, ilgili fact tabloyu dimension'larına JOIN'leyip GROUP BY ile agregasyon yapıyor (ör. gold_monthly_revenue, gold_revenue_by_category, gold_top_sellers, gold_sales_by_state, gold_avg_delivery_by_state, gold_payment_trends, gold_avg_review_score_by_category).
5. Superset'te bu 7 dataset üzerinden 7 grafik oluşturulup yeni bir dashboard'da ("Olist Star Schema Dashboard") toplandı.

6. Business Question Fact Table Dimensions

Business Question	Fact Table	Dimensions
Monthly revenue	fact_order_items	dim_date
Revenue by product category	fact_order_items	dim_product
Top-performing sellers	fact_order_items	dim_seller
Sales by customer state	fact_order_items	dim_customer
Average delivery time by state	fact_delivery	dim_customer, dim_date
Payment method trends	fact_payments	dim_payment_type, dim_date
Average review score by category	fact_reviews	dim_product, dim_date


7. Dashboard

Gold katmanındaki 4 fact ve 5 dimension tablosu üzerinden oluşturulan 7 grafik, aşağıda gruplar halinde gösterilmiştir.



Şekil 2: Monthly Revenue, Revenue by Product Category, Top-Performing Sellers.


Monthly Revenue, fact_order_items.price'ı aya göre toplar; 2017 boyunca hızlı bir büyüme, 2018'de ise sabitlenme görülüyor. Revenue by Product Category, 72 kategoriyi ciroya göre sıralıyor. Top-Performing Sellers ise en yüksek toplam satışa sahip ilk 20 satıcıyı gösteriyor — bu bilgi Faz 1'in ham tablolarında hiç yoktu, çünkü satıcı seviyesine hiç JOIN yapılmamıştı.




Şekil 3: Sales by Customer State ve Payment Method Trends.

Sales by Customer State, eyalete göre toplam ciroyu gösteriyor; SP (São Paulo) açık ara önde. Payment Method Trends, her ödeme yöntemi için zaman içindeki toplam ödeme değerini çiziyor — kredi kartı baskın ve en hızlı büyüyen yöntem, boleto ise uzak ikinci sırada.

Average Delivery Time by State



Average Review Score by Category (Score vs. Review Volume)




Şekil 4: Average Delivery Time by State ve Average Review Score by Category.

Average Delivery Time by State, fact_delivery.delivery_time_days'in eyalet bazında ortalamasını gösteriyor; SP'de ~9 gün, Roraima'da ~29 güne kadar çıkan bir aralık var. Average Review Score by Category ise bar yerine bubble chart olarak tasarlandı: X eksenı ortalama puanı, Y eksenı ve kabarcık büyüklüğü review sayısını gösteriyor, böylece hem puan hem popülerlik aynı anda görülebiliyor; 20'den az review'ı olan kategoriler istatistiksel güvenilirlik için grafikten çıkarıldı.

8. Pipeline Çalıştırma Kanıtları

Aşağıdaki iki ekran görüntüsü, pipeline'ın gerçekten çalıştırıldığını ve Gold katmanının HDFS'te fiziksel olarak oluştuğunu göstermektedir.



Şekil 5: Spark Master üzerinde tamamlanmış bir ETL job'u.

Browse Directory

/data

Go!

Show

25

entries

Search:

☐	Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name	
☐	drwxr-xr-x	root	supergroup	0 B	Jul 12 17:29	0	0 B	gold	
☐	drwxr-xr-x	root	supergroup	0 B	Jul 10 03:38	0	0 B	olist	
☐	drwxr-xr-x	root	supergroup	0 B	Jul 12 17:29	0	0 B	silver	

Şekil 6: HDFS dizin görünümü — Bronze (olist), Silver ve Gold katmanları ayrı klasörler olarak.